



Федеральное государственное образовательное бюджетное
учреждение высшего образования

**«ФИНАНСОВЫЙ УНИВЕРСИТЕТ ПРИ ПРАВИТЕЛЬСТВЕ
РОССИЙСКОЙ ФЕДЕРАЦИИ»
(Финансовый университет)**

**Институт развития профессиональных
компетенций и квалификаций**

ИТОГОВАЯ РАБОТА

Название программы	«<u>Аналитик данных</u>»
Группа обучения	AD 5 28.05.2026
Срок обучения	«с 28.05.2026 г. по 28.08.2026 г.»
ФИО	Лютых Мария Алексеевна
Тема	Исследование и оценка эффективности ассортимента компании в сфере одежды

Москва 2026 г.



Ссылки:

1. Источник данных:
https://www.kaggle.com/datasets/manishmathias/myntra-fashion-dataset?spm=a2ty_o01.29997173.0.0.b38e55fb2VXuhH
2. Визуализация Yandex Data Lens:
<https://datalens.yandex/2v0rz11hvmbil>
3. Визуализация Power BI:
Приложение к итоговой работе.
4. GitHub:
[lumarieeee/Final_project](https://github.com/lumarieeee/Final_project)

Ресурсы:

1. Данные для анализа:
Fashion_product_dataset.csv
2. Среда анализа:
Google Colab/Python (библиотеки Pandas, NumPy, Matplotlib, Seaborn)
https://colab.research.google.com/drive/1ydjfLhRwUooe4leKWzAHLSo_YgZkej6w?usp=sharing



Описание набора данных (датасета).

Исходный массив данных содержит сведения из учетной системы предприятия розничной торговли: характеристики товарных позиций и показатели реализации. Выборка включает 44 424 записи и 16 признаков.

Структура данных включает следующие поля:

- **id:** Уникальный идентификатор товара
- **gender:** Целевая гендерная аудитория товара (Men, Women, Unisex, Boys, Girls)
- **masterCategory:** Главная категория (Apparel, Footwear, Accessories, Personal Care)
- **subCategory:** Подкатегория (Tshirts, Shoes, Watches, Bags и др.)
- **articleType:** Наименование изделия (Shirts, Jeans, Tshirts, Sandal и др.)
- **baseColour:** Базовый цвет товара
- **season:** Сезонность использования (Summer, Winter, Fall, Spring)
- **year:** Год выпуска или поступления коллекции
- **usage:** Назначение товара (Casual, Formal, Sports, Party и др.)
- **productDisplayName:** Полное коммерческое наименование товара
- **price:** Цена товара
- **sold_count:** Количество проданных единиц (синтетическое поле)
- **platform:** Платформа покупки (Desktop, Mobile, Android, iOS)
- **browser:** Веб-браузер покупателя (Chrome, Safari, Edge, Firefox, Opera, Yandex Browser)
- **customer_name:** Имя клиента
- **date_added:** Дата добавления/продажи

Указанные сведения позволяют провести комплексный анализ ассортимента, выявить сезонные закономерности, оценить реакцию спроса на ценовые изменения и сегментировать товары по степени их значимости для бизнеса.



Цель работы.

Целью данной работы является закрепление и отработка навыков анализа данных, полученных в процессе изучения образовательной программы.

Задачи работы.

Для достижения поставленной цели в рамках исследования решались следующие последовательные задачи:

1. **Загрузка и первичный осмотр данных.** Импорт исходного датасета в среду Python, оценка размерности массива данных, изучение типов признаков, выявление первичных пропусков, дубликатов и потенциальных аномалий.
2. **Очистка и подготовка данных (ETL).** Формирование чистого аналитического среза, готового к моделированию. Этап включает в себя обработку пропущенных значений, удаление дубликатов, фильтрацию логически некорректных записей, приведение типов данных, а также создание новых расчетных признаков (выручка, месяц продажи, тип устройства).
3. **Исследовательский анализ данных (EDA).** Проведение углубленного статистического анализа числовых и категориальных признаков. Изучение распределений, выявление внутригодовых сезонных паттернов, анализ ценового позиционирования подкатегорий и поиск корреляционных связей между ключевыми метриками.
4. **ABC-анализ ассортимента.** Классификация товарных подкатегорий по степени их вклада в совокупную выручку. Выделение групп А, В и С для определения ключевых направлений продаж и оценки концентрации дохода на основе принципа Парето.
5. **XYZ-анализ стабильности спроса.** Расчет коэффициента вариации продаж по месяцам для каждой подкатегории. Классификация товаров на группы X, Y и Z для оценки предсказуемости спроса и волатильности продаж (с обязательным учетом ограничений, накладываемых синтетической природой данных).



6. **RFM-анализ товарных категорий.** Адаптация классического RFM-анализа под задачи управления товарной матрицей. Оценка подкатегорий по метрикам Recency (давность последней продажи), Frequency (частота транзакций) и Monetary (денежная ценность) для выявления наиболее успешных позиций и кандидатов на вывод из ассортимента.
 7. **Визуализация и дашбординг.** Создание наглядных аналитических графиков и разработка интерактивного дашборда в среде Yandex Data Lens и Power BI. Визуализация включает диаграммы категорий по выручке, график сезонности спроса, диаграмму выручки по аудитории и типу устройства и др.
 8. **Формирование практических рекомендаций.** Интерпретация полученных аналитических выводов, оценка ограничений исследования и разработка практических предложений по оптимизации товарного ассортимента, управлению складскими запасами и корректировке ценовой стратегии предприятия розничной торговли одеждой.
-



I. Очистка и подготовка данных (ETL).

Первичный осмотр и качество данных.

Исходный набор данных включает 44 424 записи и 16 признаков, разделенных на четыре числовых показателя (идентификатор, год, цена, объем реализации) и двенадцать категориальных атрибутов.

Проверка на отсутствующие значения выявила незначительные пропуски в четырех столбцах (назначение, сезон, цвет, наименование), суммарно затрагивающие менее 1% выборки, что свидетельствует о высоком качестве исходных данных. Полные дубликаты строк отсутствуют. Зафиксированное свыше 13 тысяч повторяющихся наименований товаров обусловлено бизнес-логикой: идентичные позиции реализуются по разным ценам, в различные периоды и через разные каналы сбыта.

1. Анализ и обработка пропущенных значений.

В ходе проверки на целостность данных было выявлено, что массив является достаточно полным. Пропущенные значения зафиксированы лишь в 347 строках, что составляет всего 0,78% от общего объема выборки. Наибольшее количество пропусков приходится на категориальные признаки:

- Назначение товара (*usage*) — 317 пропусков (0,71%);
- Сезонность (*season*) — 21 пропуск (0,05%);
- Базовый цвет (*baseColour*) — 15 пропусков (0,03%);
- Наименование товара (*productDisplayName*) — 7 пропусков (0,02%).

Дополнительно были выявлены и обработаны скрытые пропуски (пустые строки), которые были заменены на стандартное значение «Неизвестно» (Unknown). Для сохранения целостности структуры при последующих группировках все пропущенные значения в категориальных столбцах были заполнены этим унифицированным значением.

2. Поиск и обработка дубликатов.

Анализ на наличие полных дубликатов строк показал их полное отсутствие, что свидетельствует о корректности первичной выгрузки данных.



Дополнительно была проведена проверка на дублирование по ключевому идентификатору товара (id) — дубликатов не обнаружено. При этом выявлено более 13 000 записей с повторяющимися наименованиями товаров. Глубинный анализ показал, что это не является ошибкой ввода данных: один и тот же товар может присутствовать в наборе данных несколько раз, если он продавался в разные периоды времени, через разные платформы или по различным ценовым предложениям. В связи с этим данные записи были сохранены в полном объеме, так как они отражают реальные транзакционные операции.

3. Логическая валидация и проверка на аномалии.

Для числовых признаков (цена, объем реализации) и признака года была выполнена проверка на наличие логически невозможных значений. В результате тестирования установлено:

- Отсутствуют отрицательные значения цены и объема реализации;
- Отсутствуют нулевые значения цены;
- Все значения года находятся в логичном временном диапазоне. Выбросы и аномалии, требующие удаления записей, на данном этапе не выявлены.

4. Преобразование типов и обогащение данных.

Для корректного проведения временного анализа столбец с датой добавления/продажи был принудительно преобразован из строкового формата в формат даты и времени. Кроме того, на этапе подготовки были сгенерированы новые расчетные признаки, необходимые для дальнейшего бизнес-анализа:

- **Выручка:** рассчитана как произведение цены товара на количество проданных единиц.
- **Месяц продажи:** извлечен из даты для анализа внутригодовой сезонности.



- **Тип устройства:** создан путем агрегации платформ iOS и Android в единую категорию «Мобильное устройство» для корректного сравнения с десктопным трафиком.

В результате предобработки был сформирован чистый, структурированный и обогащенный набор данных, полностью готовый к проведению исследовательского анализа и применению алгоритмов сегментации по методам ABC, XYZ и RFM.

II. Исследовательский анализ данных (EDA).

Валидация числовых показателей.

Анализ на наличие аномалий подтвердил отсутствие логически невозможных значений: нулевых или отрицательных цен, отрицательных объемов реализации и некорректных годов выпуска. Статистические показатели цены (медиана 7 600, среднее значение 7 847) и объема реализации (медиана 58, среднее 92) подтверждают корректность данных. Высокий разброс значений (стандартное отклонение) указывает на присутствие в ассортименте как товаров массового спроса, так и нишевых позиций.

Структура категориальных признаков.

Анализ уникальных значений выявил 7 главных категорий, 45 подкатегорий и 143 типа изделий. Распределение по главным категориям показывает доминирование одежды (48,17%), за которой следуют аксессуары (25,38%) и обувь (20,75%).



Рис. 1 (линейчатая диаграмма, Yandex Data Lens)

В структуре подкатегорий лидируют верхняя одежда (34,67%) и обувь (16,53%).




Рис. 2 (древовидная диаграмма, Yandex Data Lens)

Сезонный срез демонстрирует преобладание летних (48,33%) и осенних (25,73%) коллекций. Гендерное распределение ориентировано преимущественно на мужскую (49,85%) и женскую (41,94%) аудиторию.

Анализ ценового сегментирования подкатегорий.

Агрегация данных на уровне подкатегорий позволила выявить четкое разделение на ценовые сегменты. Премиальный сегмент формируют такие подкатегории, как «Часы» (медианная цена 11 753) и «Парфюмерия» (10 960). Сегмент масс-маркета представлен «Верхней одеждой» (медианная цена 6 254) и «Брюками» (6 727). При этом наблюдается обратная зависимость: подкатегории с низкой медианной ценой демонстрируют значительно более высокие средние объемы продаж, что подтверждает стратегию высокой оборачиваемости в массовом сегменте.

Анализ внутригодовой сезонности спроса.

Группировка данных по месяцам позволила выявить выраженные сезонные колебания. Пиковые значения выручки и объема продаж приходятся

на летние месяцы: июнь (3,42 млрд), июль (3,32 млрд) и август (3,43 млрд). В то же время весенние месяцы (март, апрель, май) демонстрируют существенный спад активности, где выручка падает до уровня 313–322 млн. Разница между пиковым и минимальным месяцами превышает десятикратный размер, что требует гибкого управления товарными запасами и маркетинговыми активностями в зависимости от сезона.

Количество продаж
по season




Рис. 3 (столбчатая диаграмма, Power BI)



III. ABC-Анализ по продуктам.

Методология.

Для классификации подкатегорий по вкладу в совокупную выручку применен метод ABC-анализа, основанный на принципе Парето. Алгоритм включает группировку данных по подкатегориям с расчетом суммарной выручки, их сортировку по убыванию, вычисление процентного и кумулятивного вклада, а также распределение на три класса: А (первые 80% дохода), Б (следующие 15%) и В (оставшиеся 5%).

Результаты и интерпретация.

Анализ подтвердил действие принципа Парето: 7 подкатегорий (15% ассортимента) сформировали 80% оборота (класс А). Абсолютными лидерами стали Верхняя одежда (38,83%) и Обувь (17,12%), которые в совокупности обеспечили 55,95% выручки. Класс Б (10 позиций) включает Сандалии, Шлепанцы, Кошельки, Ремни и другие аксессуары. Класс В объединяет 28 нишевых категорий (Головные уборы, Парфюмерия, Спортивный инвентарь и др.), генерирующих лишь 5% дохода.

Выявленная структурная дифференциация указывает на то, что базовая одежда обеспечивает массовый объем транзакций, тогда как обувь и аксессуары формируют основной финансовый результат за счет более высокого среднего чека. Данный вывод обосновывает необходимость приоритетного управления складскими запасами именно для позиций класса А.




Рис. 4 (график 1, Google Colab)



IV. XYZ-Анализ по продуктам.

Методология.

Для оценки предсказуемости спроса по месяцам применен XYZ-анализ.

Алгоритм включает группировку объемов продаж по подкатегориям и месяцам, расчет среднего значения и стандартного отклонения, а также вычисление коэффициента вариации (отношение стандартного отклонения к среднему значению, выраженное в процентах). Классификация выполнена по стандартным порогам: группа X (коэффициент вариации $< 10\%$, стабильный спрос), группа Y ($10\text{--}25\%$, умеренные колебания) и группа Z ($> 25\%$, нестабильный спрос).

Результаты и интерпретация.

Анализ выявил аномальное распределение: $97,8\%$ подкатегорий отнесены к группе Z, одна категория (уход за волосами) попала в группу Y (коэффициент вариации $0,183$), а группа X отсутствует. Наиболее стабильными оказались уход за волосами и средства для кожи, тогда как спортивный инвентарь ($1,173$), нижнее белье ($1,191$) и часы ($1,451$) продемонстрировали максимальную волатильность. Для отдельных нишевых позиций расчет коэффициента невозможен из-за недостаточного объема данных.

Полученные результаты носят исключительно демонстрационный характер. Доминирование группы Z объясняется синтетической природой исходных данных об объемах продаж и недостаточной глубиной временного ряда, а не реальным поведением потребителей. Для корректного применения данного метода в реальных бизнес-процессах требуется непрерывная история транзакций продолжительностью не менее 12–24 месяцев.



V. RFM-Анализ по продуктам.

Методология.

Для классификации товарных позиций по степени их востребованности и коммерческой ценности применен метод анализа RFM. Алгоритм включает группировку данных по подкатегориям с расчетом трех метрик: давность последней продажи (в днях), частота транзакций и суммарная выручка. Каждой метрике присвоены баллы от 1 до 5 методом квантильного разбиения. Для показателя давности использована инверсия шкалы (5 баллов — наилучший результат). Итоговый рейтинг подкатегории определяется как сумма баллов (максимум 15).

Результаты и интерпретация.

Результаты ранжирования выявили абсолютных лидеров с максимальным рейтингом (15 баллов): брюки, верхняя одежда и нижнее белье. Эти категории обеспечивают основную выручку за счет высокой частоты и объема продаж. Подкатегории с рейтингом 13–14 баллов (сумки, обувь, оптика) также демонстрируют высокую коммерческую эффективность. В то же время, позиции с минимальными показателями (3–5 баллов), такие как спортивный инвентарь, перчатки и предметы домашнего обихода, характеризуются низкой ликвидностью.

Проведенный анализ позволил структурировать ассортимент, обосновав необходимость приоритетного управления запасами для ведущих категорий и проведения распродаж или полного вывода из матрицы неликвидных товаров.

VI. Визуализация данных.

Подготовка визуализаций.

Для наглядного представления результатов анализа использованы библиотеки Matplotlib и Seaborn.

Рис. 5: Распределение цен по главным категориям.

Построена диаграмма размаха (boxplot), отображающая распределение цен в разрезе главных категорий. Горизонтальная линия внутри прямоугольника отражает медианное значение цены. Анализ показывает, что медианная цена категорий «Обувь» и «Аксессуары» объективно превышает аналогичный показатель категории «Одежда». Значительная длина «усов» диаграммы (даже при исключении экстремальных отклонений) свидетельствует о широком внутреннем разбросе: в категории «Аксессуары» соседствуют как бюджетные позиции (носки, резинки), так и дорогостоящие товары (часы, брендовые сумки).




Рис. 5 (график 4, Google Colab)

Рис. 6: Внутригодовая сезонность спроса.

Линейный график демонстрирует динамику выручки по месяцам. Зафиксированы выраженные пики в летний период (июнь-август), генерирующие выручку в диапазоне 3,3–3,4 млрд единиц, и существенный спад в весенние месяцы (март-май) с показателями около 313–322 млн. Разница между пиковым и минимальным месяцами превышает десятикратный размер, что обосновывает необходимость гибкого управления товарными запасами и маркетинговыми активностями в зависимости от сезона.




Рис. 6 (график 3, Google Colab)

Рис. 7: Распределение пользователей по браузерам.

Кольцевая диаграмма демонстрирует распределение 4 099 647 пользователей по шести веб-браузерам. Абсолютное доминирование принадлежит Chrome (59,9% или 2 454 112 пользователей), за ним следуют Safari (15,6%) и Firefox (9,9%). Топ-3 браузера охватывают 85,4% аудитории, при этом браузеры на движке Chromium (Chrome, Edge, Opera) вместе составляют 71,7% рынка.



Рис. 7 (кольцевая диаграмма, Yandex Data Lens)

Рис. 8: Топ-5 самых продаваемых товаров.

Данная диаграмма отражает распределение совокупной выручки по пяти наиболее значимым подкатегориям ассортимента: верхняя одежда (7,9 млрд, 52%), обувь (3,5 млрд, 23%), сумки (1,5 млрд, 10%), брюки (1,5 млрд, 10%) и часы (1,0 млрд, 7%). Выручка от реализации верхней одежды превышает суммарный показатель четырёх остальных подкатегорий, что подтверждает действие принципа Парето: незначительная доля ассортимента формирует преобладающую часть совокупного оборота. Все представленные позиции относятся к группе А по результатам анализа по методу ABC и подлежат приоритетному управлению товарными запасами. При этом верхняя одежда и брюки обеспечивают основной объём продаж за счёт высокой скорости реализации, тогда как обувь и часы формируют существенную выручку благодаря более высокому среднему чеку.




Рис. 8 (линейчатая диаграмма, Power BI)



VII. Основные итоги и выводы.

Структура ассортимента и ценовое позиционирование.

Анализ выявил структурную дифференциацию категорий: одежда обеспечивает преобладающий объем транзакций, тогда как обувь и аксессуары генерируют основную долю выручки за счет более высокого среднего чека. Установлено, что 20% подкатегорий формируют 80% совокупного оборота, что подтверждает действие принципа Парето. Премиальный сегмент формируют часы (медианная цена 11 753), предметы красоты (11 041) и парфюмерия (10 960), тогда как массовый сегмент представлен верхней одеждой (6 254) и товарами для ухода (6 549–6 667).

Сезонность и каналы продаж.

Выявлены выраженные пики продаж в летний период (июнь–август), генерирующие выручку 3,3–3,4 млрд, и существенный спад весной (март–май) до 313–322 млн. Разница между пиковым и минимальным месяцами превышает десятикратный размер, что обосновывает необходимость гибкого управления запасами. Зафиксированы различия в распределении выручки между каналами продаж, однако интерпретация этих данных требует учета гендерной принадлежности товара, а не реального покупателя.

Ограничения исследования.

Ключевым ограничением выступает синтетический характер данных о продажах и отсутствие информации о себестоимости. Для повышения практической значимости результатов необходимо обогащение модели данными о фактических складских остатках, промо-активностях и извлечение информации о брендах из текстовых описаний.



Заключение.

Проведенное исследование позволило классифицировать ассортимент по выручке, стабильности спроса и частоте покупок. Выполнена очистка и подготовка 44 424 записей, созданы расчетные признаки (выручка, месяц продажи, тип устройства). ABC-анализ выявил 7 ключевых подкатегорий, генерирующих 80% выручки. RFM-анализ выделил приоритетные категории (верхняя одежда, брюки и нижнее белье) с максимальным рейтингом. XYZ-анализ показал ограничения метода при работе с синтетическими данными.

Практические рекомендации.

1. Управление ассортиментом: поддерживать непрерывную доступность товаров класса А, оптимизировать запасы класса Б, провести распродажи или вывод из матрицы класса В.
2. Ценовая стратегия: сфокусироваться на массовом сегменте, развивать премиум-линейки, внедрить дифференцированное ценообразование.
3. Сезонное планирование: увеличить запасы на 30–40% в летне-осенний период, запустить промо-кампании в весенние месяцы.
4. Маркетинг: стимулировать сопутствующие продажи категорий одежды и аксессуаров, разработать программу лояльности для приоритетного сегмента.

Перспективы развития.

Для повышения точности анализа рекомендуется интегрировать реальные данные о продажах, добавить информацию о себестоимости и маржинальности, расширить временной период до 12–24 месяцев.

Применение методов сегментации позволило структурировать ассортимент по степени финансовой значимости и стабильности спроса, выявив скрытые закономерности. Полученные выводы формируют основу для принятия управленческих решений, оптимизации продуктового портфеля и повышения эффективности использования капитала. Дифференцированный подход к управлению запасами минимизирует риски дефицита ключевых позиций и способствует укреплению конкурентных позиций предприятия.